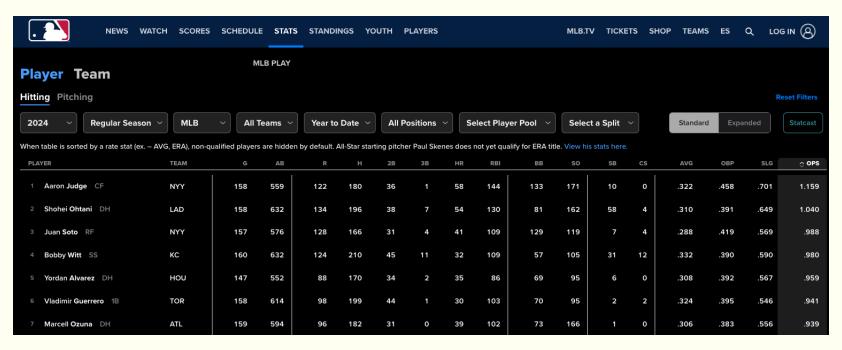


HW2-Problem6 MLB Data Crawling and Analysis

Introduction to the problem6 of hw2









要求

- 使用 Scrapy 自己生成爬蟲框架(不提供程式碼)
- https://www.mlb.com/stats/
 爬取此網頁中所有球員的各項指標(6頁都要抓到)
- 繳交整個爬蟲程式,不包含輸出 csv
- 使用網頁表格的表頭名稱作為輸出檔案的欄位名稱
- 球員名字後面的守備位置不用抓

評分方式

- TA 會執行同學的 爬蟲程式,得到程 式的輸出檔
- 而後與 TA 自己的 csv 檔案進行內容 比較





STEP 1: 安裝 Scrapy

STEP 2: 建立爬蟲專案

STEP 3: 建立爬蟲程式

pip + venv

pip install Scrapy # 安裝 scrapy version # 確認安裝成功

conda

conda install conda-forge::scrapy # 安裝 scrapy version # 確認安裝成功



STEP 1: 安裝 Scrapy

STEP 2: 建立爬蟲專案

STEP 3: 建立爬蟲程式

使用 terminal 建立 scrapy 專案 完成後會看到如右圖的結構

scrapy startproject ct_name>

```
tutorial/
                   # 專案環境設定
  scrapy.cfg
  tutorial/ # 撰寫成 module
      __init__.py
                   # 定義抓取的內容
      items.py
      middlewares.py
                   # 中介流程,在各元件溝通之間作用
                   # items 的處理流程
      pipelines.py
      settings.py
                   # 設定檔案
      spiders/ # 爬蟲程式資料夾
         __init__.py
```



STEP 1: 安裝 Scrapy

STEP 2: 建立爬蟲專案

STEP 3: 建立爬蟲程式

使用 terminal 建立爬蟲程式 設定爬蟲名稱與爬取的網域 cd cd crapy genspider <spider_name> <domain>



cd cd cd cd project_name>/spider
scrapy genspider <spider_name> <domain>

STEP 1: 安裝 Scrapy

STEP 2: 建立爬蟲專案

STEP 3: 建立爬蟲程式

此時你已成功建立爬蟲程式的 框架!(開始寫作業吧)

02 MLB 資料視覺化

MLB 資料視覺化

要求

- 使用提供的 hw2_template.ipynb 模板
- 計算所有大聯盟球員的平均得分(Runs) 將球員分為「高得分」與「低得分」兩組
- 將兩組球員的 *得分指標 全部相加 畫出這兩組的 correlation matrix
- 解釋你對結果的看法

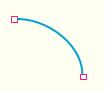
評分方式

TA 執行你的 .ipynb,檢驗是否畫出正確圖表

*得分指標

- 得分(Runs Scored, R)
- 打點 (Runs Batted In, RBI)
- 安打數(Hits, H)
- 全壘打數 (Home Runs, HR)
- 打擊率 (Batting Average, AVG)
- 上壘率(On-Base Percentage, OBP)
- 長打率 (Slugging Percentage, SLG)
- 盗壘數(Stolen Bases, SB)
- 打數 (At Bats, AB)
- 四壞球率(Walks, BB)
- 被三振數(Strikeouts, SO)

Thanks!



Do you have any questions?

Please mail to Netai-2024@googlegroups.com

CREDITS: This presentation template was created by $\underline{\textbf{Slidesgo}}$, and includes icons by $\underline{\textbf{Flaticon}}$, and infographics & images by $\underline{\textbf{Freepik}}$

Please keep this slide for attribution

